

网络数据的多重深度及其应用

张茂雨，邓林遂，戴文林

1 摘要

在多个研究领域中，对网络型数据的分析需求日益增长。为了促进对此类数据的稳健分析，本文提出了一种名为多重深度（multiplex depth）的新型深度概念，它将针对多元数据的Tukey深度推广到网络数据领域。该深度同时适用于二值网络和加权网络，能够实现数据排序和异常值检测。我们研究了多重深度与深度相关的性质，并建立了样本深度和基于深度的中位数估计量的一致性。此外，我们设计了高效的计算算法以促进实际应用。为了评估我们方法的有效性，我们使用模拟数据和一个基于神经科学的脑网络数据集进行了全面评估。该评估涵盖了数据排序、中心估计和异常值检测等关键任务，确保了对我们方法的全面而严谨的分析。本文的补充材料可在网上获取。

关键词：数据排序；异常值检测；统计深度；子图结构；双样本检验

2 引言

网络是一种广泛使用的数据结构，用于描述对象之间的关系，由一组顶点和连接顶点的边组成。在这种结构中，顶点代表对象本身，边代表对象之间的关系。网络数据的重要性因其在社交网络（Liu, Patacchini, and Rainone 2017; Zhu et al. 2020; Zhang, Zhang, and Dai 2024）、生物网络（Zhang and Cao 2017; Zhang et al. 2024）、金融网络（Han et al. 2016; Zou et al. 2017; Accominotti, Lucena-Piquero, and Ugolini 2023）和交通网络（Dubey and Müller 2022; Zhang et al. 2022）等领域的广泛应用而受到大量关注。在本文中，我们交替使用“网络”和“图”这两个术语。

大多数研究集中在分析单个网络上，例如社区检测（Khan and Niazi 2017; Abbe 2017; Zhang, He, and Wang 2022）、度分布估计（Hay et al. 2009）或子图强度估计（Chang, Kolaczyk, and Yao 2020）。然而，对多个网络的分析（也称为网络型数据）受到的关注逐渐增加，其中数据的基本单位是单个网络（Lovato et al. 2020, 2021）。对网络型数据的大多数研究集中在总体建模（Durante, Dunson, and Vogelstein 2017; Lunagómez, Olhede, and Wolfe 2021）、双样本检验（Maugis et al. 2020; Durante and Dunson 2018; Xia and Li 2022; Hu 2019; Lovato et al. 2020, 2021）、社区检测（Barbillon et al. 2017; Rohe, Chatterjee, and Yu 2011; Paul and Chen 2020）和其他领域（Jiang, Munger, and Bunke 2001; Han et al. 2016）。上述讨论的多网络数据通常由共享相同顶点集的网络样本组成，这也是本文考虑的情形。

网络分析中的一个基本挑战是，如果网络型数据被异常值污染，其结论可能会产生误导。网络异常值可以大致分为顶点级异常值和样本级异常值（Hodge and Austin 2004; Zhang, Meratnia, and Havinga 2010; Gupta et al. 2014）。顶点级异常值是单个网络内部异常的顶点，可能出现在各种领域中。样本级异常值是表现出异常模

式的特殊网络。例如，在阿尔茨海默病患者中，通过fMRI扫描观察到的功能响应或模式与健康老龄化个体中观察到的不同（Greicius et al. 2004）。许多研究集中在检测样本级异常值上，例如Gupta et al. (2014) 基于网络社区和图相似性检测异常值，使用了各种度量（Papadimitriou, Dasdan, and Garcia-Molina 2010; Donnat and Holmes 2018）。挖掘子网络结构可以全面识别和解释样本级异常值（Dang et al. 2016）。顶点级和样本级异常值都具有挑战性。对于本文考虑的多网络情况，我们关注样本级异常值，这促使我们开发一种基于统计深度的稳健方法。

统计深度是一种根据数据潜在分布来度量数据中心性或离群程度的方法，从而将顺序统计量的概念推广到多种数据类型，如多元数据和函数型数据（Tukey 1975; Liu 1990; López-Pintado and Romo 2009）、方向或球面数据（Pandolfo, Paindaveine, and Porzio 2018）、矩阵数据（Chen, Gao, and Ren 2018; Paindaveine and Van Bever 2018）、曲线数据（Lafaye de Micheaux, Mozharovskiy, and Vimond 2021）和集合数据（Cascos, Li, and Molchanov 2021）。Zuo and Serfling (2000a) 提出了多元数据深度的统一定义，并研究了四个关键的期望深度性质。在网络数据中构建深度的其他尝试主要集中在单网络情形上。例如，Bertagnolli, Agostinelli, and De Domenico (2020) 采用了一种新颖的方法，为投影的Tukey深度配备了网络嵌入度量来识别顶点的中心性，而Raj et al. (2017) 将带深度扩展到特定网络内的路径集合上，以系统性地可视化路径。那么一个自然的问题是：如何为多个网络建立一个结合网络结构并扩展深度性质的深度函数？

我们提出了一种针对网络型数据的深度概念，称为多重深度（multiplex depth）。该概念将Tukey深度推广到多网络领域，能够实现高效的异常值检测和网络排序。多重深度框架适用于所有无权/加权和有向/有向网络，并配备高效的计算算法。这项工作是将Tukey数据深度概念扩展到多网络领域的首次尝试，尽管它承认其适用性存在一些限制。我们的贡献是多方面的。首先，我们将深度概念引入多网络领域，结合了全局和局部网络结构。其次，我们建立了所提出的深度度量的性质，并证明了基于深度的中心与总体中心的一致性。此外，我们引入了与网络结构相关的结构权重（structure weight），这显著增强了排序结果的可解释性。最后，我们通过模拟和对脑连接性的研究验证了我们方法的有效性，涵盖了数据排序、中心估计和异常值检测。

作为定义网络数据深度的初步步骤，本文考虑定义在公共顶点集上的一组成立的网络样本。这些假设在生物信息学（Zhang and Cao 2017）和神经科学（Zhou and Li 2014; Zhang et al. 2024）等研究领域的网络中得到了很好的满足，但在某些其他领域（如社交网络和经济网络）中可能不成立，因为这些领域中的顶点集在不同样本之间可能变化。我们将框架扩展到更一般情形的任务留作未来工作。

本文的其余部分安排如下。第2节描述了网络的一般化深度概念，称为（子图）多重深度，首先关注整个网络，然后逐渐转向子图。我们深入研究了边多重深度函数作为一个重要的特例，并引入了专门为网络分析定制的结构权重。在第3节中，我们考察了边多重深度的理论性质，并推导了基于深度的经验中心与总体中心之间的一致性。在第4节中，我们评估了所提出的深度在无权图和加权图上的性能，包括数据排序、中心估计和异常值检测。在第5节中，我们将所提出的深度应用于分析一个脑电图数据集，执行中心估计、异常值检测和双样本检验等任务。第6节提供讨论。

3 1.1. 记号

设 $\mathbf{G} = (\mathbf{V}, \mathbf{E})$ 表示一个没有重复边或自环的网络，其中 $V = [N] = \{1, 2, \dots, N\}$, $N \geq 2$, 是顶点集, $E = \{e(i, j) : i, j \in V, i \neq j\}$ 是边集。网络 $\mathbf{G}$ 可以是无权或加权、有向或无向的，定义在相同的顶点集上。对于无权网络，我们定义 $e(i, j) := (i, j)$, 且 $e(i, j) \in E$ 表示边的存在。对于加权网络， $e(i, j) \in \mathbb{R}$ 表示边

的权重。在有向网络中，边从 i 指向 j ；在无向网络中， $e(i, j) = e(j, i)$ 。一个网络 G 可以唯一地由其邻接矩阵 A^G 表示，其对角线元素为零，其中对于无权网络 $A_{ij}^G = \mathbf{1}_E(e(i, j))$ ，对于加权网络 $A_{ij}^G = e(i, j)$ 。对于稀疏加权网络，我们将缺失边的权重设为零，以使我们的方法能够应用。我们使用 $\|A\|_1 = \sum_{i=1}^N \sum_{j=1}^N |A_{ij}|$ 和 $\|A\|_\infty = \max_{i,j=1}^N |A_{ij}|$ 来度量矩阵 A 的 L_1 和 L_∞ 范数。我们专注于标记网络，并将所有 N 顶点标记网络的集合记为 $\mathcal{G}_{[N]} := \{(V, E) : V = [N]\}$ 。考虑概率空间 $(\mathcal{G}_{[N]}, \mathcal{F}, pr)$ ，其中 $\mathcal{F}$ 是一个 σ -域。我们的观测值是一个由 $n \geq 2$ 个网络组成的网络集合 $\mathcal{G}_n = \{G_l\}_{l=1}^n = \{(V, E^l)\}_{l=1}^n$ 。为了强调网络的随机性，我们使用粗体如 $\mathbf{G}$ 或 $\mathbf{A}$ 以避免混淆。此外，我们使用斜体的结构权重来表示与所提出的多重深度相关的权重，从而将它们与边的权重区分开来。

此外，我们考虑两个网络 $G_a = (V, E^a)$ 和 $G_b = (V, E^b) \in \mathcal{G}_{[N]}$ ，并在 $\mathcal{G}_{[N]}$ 上引入一个偏序。对于无权网络，如果 $E^a \subset E^b$ ，则 $G_a \subseteq G_b$ ；对于加权网络，如果 $e^a(i, j) \leq e^b(i, j)$ ， $i \neq j \in [N]$ ，则 $G_a \preceq G_b$ 。该序关系可以自然地用相应的邻接矩阵表示。

4 网络的多重深度函数

4.1 动机：全局多重深度

在本节中，我们提供一种方法来衡量一个网络 $G \in \mathcal{G}_{[N]}$ 关于概率空间 $(\mathcal{G}_{[N]}, \mathcal{F}, pr)$ 的代表性。概率空间的例子包括无权网络的 Erdős-Rényi 模型 (Gilbert 1959)、单峰网络分布 (Lunagómez, Olhede, and Wolfe 2021) 和随机测量误差模型 (Chang, Kolaczyk, and Yao 2020)，以及加权网络的高斯图模型 (Ren et al. 2015)。粗略地说，我们构建一个由 $k \geq 2$ 个从 $(\mathcal{G}_{[N]}, \mathcal{F}, pr)$ 中随机抽样的网络 $\mathbf{G}_1, \mathbf{G}_2, \dots, \mathbf{G}_k$ 组成的多重结构 (multiplex)，该结构包含一个上层和一个下层。值得注意的是，在实践中，我们的模型不需要从总体中生成样本，也不需要估计总体。相反，我们基于给定的网络样本来构建多重深度。

基于上述直觉，我们分别考虑对 K 个无权或加权网络构建多重结构。在我们的框架中，假设网络是有向的；然而，该方法同样适用于无向网络，由于对称性，只需要计算上三角或下三角图。从无权网络开始，多重结构的上层和下层为：

$$\begin{aligned} G^{\text{up}}(G_1, G_2, \dots, G_k) &= (V, E^{\text{up}} = \cup_{l=1}^K E^l), \\ G^{\text{down}}(G_1, G_2, \dots, G_k) &= (V, E^{\text{down}} = \cap_{l=1}^K E^l). \end{aligned}$$

为简化记号，在不引起歧义的情况下，我们使用 G^{up} 和 G^{down} 。构建的多重结构定义为：

$$M(G_1, G_2, \dots, G_k) = \{G : G^{\text{down}} \subset G \subset G^{\text{up}}\} = \{(V, E) : E^{\text{down}} \subset E \subset E^{\text{up}}\}.$$

直观地说，一个具有代表性的网络很可能位于上层和下层之间。因此，如果 G 落在多重结构内部，它就是一个具有代表性的网络；否则，它是一个异常值。图1给出了由两个网络构建的多重结构的示例，以及一个位于多重结构之外的样本。对于加权网络，多重结构类似地构建为：

$$M(G_1, G_2, \dots, G_k) = \{G : G^{\text{down}} \preceq G \preceq G^{\text{up}}\} = \{(V, E) : e^{\text{down}}(i, j) \leq e(i, j) \leq e^{\text{up}}(i, j), i \neq j \in [N]\},$$

其中 $e^{\text{up}}(i, j) = \max_{l=1,2,\dots,k} e^l(i, j)$, $e^{\text{down}}(i, j) = \min_{l=1,2,\dots,k} e^l(i, j)$ 。二值网络可以视为边权为0或1的加权网络。但这并不意味着简单地将无权网络视为加权网络，因为它们建立在不同的支撑集上，并且具有不同的理论性质。

上述构造仅反映了 G 与给定的 k 个网络之间的一致性。我们关注 G 与 $pr(\cdot)$ 的符合程度，这可以通过 G 被包含在由来自 $(\mathcal{G}_{[N]}, \mathcal{F}, pr)$ 的 k 个随机网络构建的多重结构中的概率来衡量。我们在总体水平上将多重深度定义为：

$$MD_{pr}^k(G) = \mathbb{E}(\mathbf{1}\{G \in M(\mathbf{G}_1, \mathbf{G}_2, \dots, \mathbf{G}_k)\}) = pr\{G \in M(\mathbf{G}_1, \mathbf{G}_2, \dots, \mathbf{G}_k)\}.$$

实际上，给定一个网络集合 $\mathcal{G}_n$, $n \geq k$ ，我们可以使用 U 统计量来估计 $MD_{pr}^k(G)$ ：

$$MD_n^k(G) = \binom{n}{k}^{-1} \sum_{1 \leq l_1 < l_2 < \dots < l_k \leq n} \mathbf{1}\{G \in M(G_{l_1}, G_{l_2}, \dots, G_{l_k})\},$$

它衡量了由 $\mathcal{G}_n$ 中所有 k 个网络组合构建的多重结构中包含 G 的比例。通过汇总在不同 k 值上分别建立的值，我们可以定义全局多重深度（gMD）来一次性考虑网络的全局结构。 G 的样本和总体版 gMD 定义为：

$$\begin{aligned} gMD_n^K(G) &= \sum_{k=2}^K MD_n^k(G), \\ gMD_{pr}^K(G) &= \sum_{k=2}^K MD_{pr}^k(G), \end{aligned}$$

其中 $M(\cdot)$ 、 $MD_{pr}^k(\cdot)$ 和 $MD_n^k(\cdot)$ 分别在 (2)-(4) 中定义。如 López-Pintado and Romo (2009) 所述，gMD 反映了网络的代表性，因此自然地引入了排序。然而，边权的变异性可能导致没有任何网络完全包含在任何多重结构中，特别是当网络规模较大时。此时 gMD 可能退化，因为所有网络都被赋予零深度而无法区分。我们通过将注意力从全局结构转向局部结构（即子图）来解决这个问题。

4.2 一般子图多重深度

在本节中，我们通过考虑常见的子图结构（如边、二星、三元组、三角形和链）(Balachandran, Kolaczyk, and Viles 2017; Maugis et al. 2020; Chang, Kolaczyk, and Yao 2020) 来修改多重深度。构建这种新深度的主要步骤是：(a) 选择特定感兴趣的子图结构；(b) 将所选子图视为完整图来计算 gMD；(c) 在相同结构的所有子图上积分 gMD 值。我们首先引入网络限制到子图指示符的概念，然后建立一般的子图多重深度。

定义 1. 定义一个没有重复边或自环的无权网络 $H = (V^H, E^H) \in \mathcal{G}_{V^H}^{(u)}$ 为 $\mathcal{G}_{[N]}$ 的一个子图指示符，如果

$V^H \subset [N]$ 且 $E^H \subset V^H \times V^H$ 。

定义 2. 考虑一个网络 $G = (V^G, E^G) \in \mathcal{G}_{[N]}$ 和 $\mathcal{G}_{[N]}$ 的一个子图指示符 H 。将 G 限制在 H 上的子图记为 $G|_H = (V^{G|_H}, E^{G|_H})$, 其中 $V^{G|_H} = V^H$, $E^{G|_H} = \{e^{G|_H}(i, j) : i, j \in V^{G|_H}, i \neq j\}$, 且 $e^{G|_H}(i, j) = e^G(i, j)\mathbf{1}\{e(i, j) \in E^H\}$ 。

定义1和2清晰地展示了 gMD 被限制在 $\mathcal{G}_{[N]}$ 的一个给定的子图指示符上。此外, 我们还对限制在与该指示符同构的所有子图指示符上的 gMD 感兴趣。在指定子图指示符之后, 我们在每个同构子图上获得全局多重深度。整合这些 gMD 值的一个直接策略是平等对待它们并取平均值。在实践中, 额外的信息可能表明某些子图比其他子图对于描述整个样本更为关键, 因此分配相对的结构权重是一个理想的选择。关于结构权重的详细讨论见第2.3节。这样, 我们现在可以正式提出子图多重深度。

图1 子图多重结构的示意图。粗框标出了位于 G 的多重结构中的情形。较大的顶点是所考察的子图指示符的顶点。面板 B 展示了由 G_1 和 G_2 构建的全局多重结构。面板 C 和 D 展示了限制在所考察的子图指示符上的多重结构和目标网络。在面板 D 中, 二星指示符的中间顶点用粉色表示。

定义 3 (子图多重深度)。设 K 为一个满足 $2 \leq K \leq n$ 的固定整数。给定 $\mathcal{G}_{[N]}$ 的一个子图结构指示符 H 和结构权重 $\mathbf{w} = \{w_{H'}\}_{H' \cong H} \geq 0$ 且 $\sum_{H' \cong H} w_{H'} = 1$, 样本版本和总体版本的子图多重深度定义为:

$$sMD_{n,H}^K(G; \mathbf{w}) = \sum_{H' \cong H} w_{H'} gMD_n^{H',K}(G|_{H'}),$$

$$sMD_{pr,H}^K(G; \mathbf{w}) = \sum_{H' \cong H} w_{H'} gMD_{pr}^{H',K}(G|_{H'}),$$

其中 $gMD_n^{H',K}$ 和 $gMD_{pr}^{H',K}$ 分别是 (5) 中定义的由限制在 H' 上的网络集合构建的样本和总体版本 gMD。

图1给出了三种不同的感兴趣结构 (全局结构、三角形和二星) 的示例。在这些结构上 sMD 有所不同。在面板 B 中, G 位于全局多重结构之外, 因为 G 中的 $e(a, d)$ 没有出现在 G^{up} 中, 而 G^{down} 中的 $e(c, d)$ 未能包含在 G 中; 因此 $gMD_2^2(G) = 0$ 。在面板 C 中, 感兴趣的结构是三角形。在四个同构子图中有一个发生包含, 得到 $sMD_{2,\triangle}^2(G) = 1/4$ 。在面板 D 中, 关注的是二星结构, 在12个同构子图中有5个包含在内, 得到 $sMD_{2,\text{two-star}}^2(G) = 5/12$ 。对于边, $sMD_{2,\text{edge}}^2(G) = 2/3$, 因为 G 中6条边中有4条位于由 G_1 和 G_2 形成的多重结构中。子图多重深度可以被看作是全局图上 gMD 的软版本, 它计算了具有特定结构的子图集合上 gMD 的 (加权) 平均。

4.3 边多重深度

边是网络分析中一种普遍存在的子图类型, 同时, 更简单的子图结构导致更可区分的深度函数。因此, 我们关注由这种基本结构导出的深度概念, 称为边多重深度 (eMD)。这种特例是 gMD 的一个比基于其他子结构的深度更直观的软版本, 因为它将完全包含的要求放宽为允许部分包含。在下面的讨论中, 我们考察样本版本 eMD 的可解释性和计算可行性。

根据定义3, 将 $\mathcal{G}_{[N]}$ 的边指示符记为 $\overline{H_{i,j}} = (V^{H_{i,j}}, E^{H_{i,j}})$, 其中 $V^{H_{i,j}} = \{i, j\} \subset [N]$, $E^{H_{i,j}} = \{e(i, j)\}$, $i \neq j$ 。那么 $H_{i,j}$ 的同构集由所有可能的边组成。结构权重可以方便地由一个零对角线的矩阵 $W = (w_{ij})$ 表示, 其中

$w_{ij} \geq 0$ 且 $\sum_{i \neq j} w_{ij} = 1$ 。样本版本和总体版本的边多重深度定义为：

$$eMD_n^K(G; W) = \sum_{i \neq j} w_{ij} gMD_n^{H_{i,j}, K}(G|_{H_{i,j}}),$$

$$eMD_{pr}^K(G; W) = \sum_{i \neq j} w_{ij} gMD_{pr}^{H_{i,j}, K}(G|_{H_{i,j}}).$$

上述形式 (6) 和 (7) 将全局多重深度限制在单条边上，然后以结构权重取深度值的加权平均。eMD 的另一种解释（即 gMD 的一个软加权版本）可以通过重新排列 (6) 得到：

$$\begin{aligned} eMD_n^K(G; W) \& = \sum_{i \neq j} w_{ij} gMD_n^{H_{i,j}, K}(G|_{H_{i,j}}) \\ \& = \sum_{i \neq j} w_{ij} \sum_{k=2}^K \left(\binom{n}{k}^{-1} \sum_{1 \leq l_1 < l_2 < \dots < l_k \leq n} \mathbf{1}\{G|_{H_{i,j}} \in M(G_{l_1}|_{H_{i,j}}, \dots, G_{l_k}|_{H_{i,j}})\} \right) \\ \& = \sum_{k=2}^K \binom{n}{k}^{-1} \sum_{1 \leq l_1 < l_2 < \dots < l_k \leq n} \sum_{i \neq j} w_{ij} \mathbf{1}\{G \in EM_{H_{i,j}}(G_{l_1}, \dots, G_{l_k})\} \\ \& \triangleq \sum_{k=2}^K eMD_n^k(G; W), \end{aligned}$$

其中 $EM_{H_{i,j}}(G_{l_1}, \dots, G_{l_k}) = \{G(V, E) : e(i, j) \in [e^{\text{down}}(i, j), e^{\text{up}}(i, j)]\}$ 是边多重结构。

网络落入边多重结构的指示符的加权平均提供了完全包含和完全排除之间的中间度量，即部分包含。类似地，相对于总体 $pr(\cdot)$ 的总体版本 eMD 的分量可以表示为：

$$eMD_{pr}^k(G; W) = \sum_{i \neq j} w_{ij} pr\{G \in EM_{H_{i,j}}(\mathbf{G}_1, \mathbf{G}_2, \dots, \mathbf{G}_k)\}.$$

与 (5) 比较，在 $MD_n^k(G)$ 和 $MD_{pr}^k(G)$ 中的完全包含被 (8) 和 (9) 中由结构权重加重的部分包含所替代。当没有先验信息时，建议使用恒定的结构权重（即 $w_{ij} = 1/(N \times (N - 1))$ ）。否则，可以使用非均匀权重来考虑感兴趣网络结构的重要性，类似于在函数型深度中纳入权重函数的想法（Claeskens et al. 2014）。我们对 eMD 结构权重的设计基于 Koutra et al. (2016) 提出的相似性得分原则，如边重要性、边次模性、权重感知和焦点感知。此外，函数型数据中的加权深度具有焦点感知的性质（Claeskens et al. 2014）。这使我们能够在表1中开发典型的结构权重。研究者可以根据实际应用确定结构权重的类型。

在实践中，K 的选择需要在计算效率和排序稳定性之间权衡。直观上，较大的 K 会边际地提高稳定性，但需要更多的计算。如 Staerman et al. (2020) 所述，基于深度的排序不会随 K 有太大变化，实践中更倾向于较小的 K 值。此外，(8) 中第二行的表达式表明 eMD_n^K 的计算退化为一个一维排序问题。遵循 Sun, Genton, and Nychka (2012) 的思路，并受无权网络二值性质的启发，我们开发了一种快速算法，极大地提高了 eMD_n^K 的计算效率。我们在补充材料的第 SII 节中详细介绍了无权网络和加权网络的 eMD_n^K 快速算法。模拟结果将表

明估计精度对 K 的选择不敏感（参见第4.1和4.2节）。我们还在第4.3节中比较了计算成本。

表1. 三种结构权重类型： (i) 等权重, (ii) 顶点权重, (iii) 边权重。| 类型 | 依据 | 依据详情 | 未归一化权重 $\widetilde{W}_{ij}$ ($i \neq j$) | |—|—|—|—| 等权重 | — | — | 1 | | 顶点权重 | 顶点 i 的中心性 $\{c_{i,l}\}$ | 度、接近、介数、特征向量中心性 | $\frac{\sum_{l=1}^n (c_{i,l} + c_{j,l})}{2n}$ | | 边权重 | 边 $e(i,j)$ 的中心性 $\{b_{ij,l}\}$ | 经过该边的最短路径数 | $\frac{\sum_{l=1}^n b_{ij,l}}{\#\{l: b_{ij,l} \neq 0\}}$ | > 注：给定 $\mathcal{G}_n$, 未归一化权重的非对角元素根据顶点中心性 (Newman 2010) 和边中心性 (Newman, Watts, and Strogatz 2002) 定义, 对角元素为零。归一化结构权重为 $W = \widetilde{W} / \|\widetilde{W}\|_1$ 。

5 理论性质

本节证明 eMD 满足统计深度通常所需的性质, 并推导深度值和基于深度的中心网络的渐近收敛性。我们还在补充材料的第 SV 节中给出了 gMD 的结果。在本节中, 我们交替使用 G 或其邻接矩阵 A 来表示网络, 因为它们共享相同的上标和下标。

5.1 深度性质

Zuo and Serfling (2000a) 建立了多元数据深度函数应满足的四个典型性质: (i) 中心处极大性; (ii) 相对于中心的单调性; (iii) 仿射不变性; (iv) 无穷远处消失性。在本节中, 我们考察加权网络中 eMD 的类似深度性质。记 A_{ij} 和 pr_{ij} 分别为边 (i,j) 的权重及其分布。

假设 1. 对所有 i,j , pr_{ij} 是紧的, 即当 $M \rightarrow \infty$ 时 $Pr_{ij}(|A_{ij}| \geq M) \rightarrow 0$, 且绝对连续, 即存在概率密度函数 f_{ij} 使得对 $\mathbb{R}$ 中的任何可测集 B , 有 $pr_{ij}(B) = \int_B f_{ij}(x)dx$ 。

假设 2. 记 $G^c = (V, E^c)$, 其邻接矩阵为 A^c 。假设 pr 关于 G^c 对称, 即 $(A_{ij} - A_{ij}^c)$ 和 $-(A_{ij} - A_{ij}^c)$ 具有相同的分布。

假设1和2要求边权边际分布绝对连续、紧且关于中心网络对称。这些假设被由高斯图模型 (Liu 2013; Ren et al. 2015) 和对称正定矩阵的黎曼高斯分布 (Zanini et al. 2016) 导出的网络所满足。例如, 来自多个受试者的脑相关网络通常表现出以共同网络为中心的高斯分布。

定理 1 (加权网络中 eMD 的深度性质)。 在假设1和2以及 $w_{ij} > 0$ 下, 我们有:

(a) **中心处极大性:** 如果密度 f 在 G^c 中心的一个邻域内进一步为正, 则 $eMD_{pr}^K(\cdot; W)$ 在 G^c 处唯一地达到最大值。

(b) **相对于中心的单调性:** 给定 $G \in \mathcal{G}_{[N]}$ 和缩放参数 $\alpha > 0$, 定义 G^α 为一个邻接矩阵为 $\alpha(A^G - A^c)$ 的网络, 则 $eMD_{pr}^K(G^\alpha; W)$ 是关于 α 的单调非增函数。

(c) **无穷远处消失性:** $\sup_{\|A^G\|_\infty \geq M} eMD_{pr}^K(G; W) \rightarrow 0$, 且当 $M \rightarrow \infty$ 时 $\sup_{\|A^G\|_\infty \geq M} eMD_n^K(G; W) \xrightarrow{\text{a.s.}} 0$ 。

(d) **仿射不变性:** (d)-(i) 考虑变换 $T: \mathcal{G}_{[N]} \mapsto \mathcal{G}_{[N]}$ 。设 G 和 $T(G)$ 的邻接矩阵分别为 A 和 $C \odot A + D$, 其中 $C, D \in \mathbb{R}^{N \times N}$, $\odot$ 为哈达玛积。如果 $C_{ij} \neq 0$, 则 $eMD_n^K(G) = eMD_n^{K, T(G)}(T(G))$ 且 $eMD_{pr}^K(G) = eMD_{pr \circ T^{-1}}^K(T(G))$ 。(d)-(ii) 考虑 $\pi: [N] \mapsto [N]$, 顶点的置换变换, 它诱导出变换 $\pi^G: \mathcal{G}_{[N]} \mapsto \mathcal{G}_{[N]}$ 和 $\pi^W: \mathbb{R}^{N \times N} \mapsto \mathbb{R}^{N \times N}$ 。那么 $eMD_n^K(G; W) = eMD_n^{K, \pi^G(G)}(\pi^G(G); \pi^W(W))$ 且 $eMD_{pr}^K(G; W) = eMD_{pr \circ (\pi^G)^{-1}}^K(\pi^G(G); \pi^W(W))$ 。

定理1正式定义了 eMD 的四个深度性质。仿射不变性有两个方面：定理1(d)-(i) 表明对所有网络应用相同的边仿射变换不会影响 eMD 的值；定理1(d)-(ii) 涉及网络结构：当顶点的标签改变时，eMD 保持不变。如定理 S2 所述，gMD 对加权网络具有类似的深度性质，其中”中心处极大性”、”相对于中心的单调性”和”无穷远处消失性”从函数型数据的修正带深度（López-Pintado and Romo 2009）推广而来。

对于无权网络，我们首先在假设 S1 下的定理 S1 中建立了 gMD 的四个深度性质。鉴于无权网络是通过相对于中心网络 G^c 扰动边的存在性而生成的，假设 S1 要求边扰动的独立性以及这些扰动的指定概率，这可以由一系列含噪网络（Chang, Kolaczyk, and Yao 2020）满足。注意，边的独立性在流行的网络模型中是一个相当常见的假设，例如随机块模型（Wang and Wong 1987; Zhang, Sun, and Li 2020）和潜在空间模型（Ma, Ma, and Yuan 2020; Hof, Raftery, and Handcock 2002）。这个假设对于证明无权网络的 gMD 和 eMD 的收敛性（定理2和 S3）也是至关重要的。特别地，对无权网络的仿射不变性性质1(d)-(i) 表示对某些选定的顶点对翻转边的存在性。

由于 eMD 可以视为 gMD 的加权平均，如第2.3节所述，从 gMD 到 eMD 对加权网络和无权网络的推广是直接的，这在 Claeskens et al.（2014）中针对多元数据的类似推广中已经提到。

5.2 收敛性

我们在三个主要方面建立收敛性：(i) gMD 和 eMD 的点态收敛性；(ii) eMD 在 $\mathcal{G}_{[N]}$ 上的一致收敛性；(iii) 估计的最深网络的一致性。由于 (4) 和 (8) 中的 MD 和 eMD 是以（加权）示性函数为核的 U 统计量，我们可以推导出它们的点态收敛性。

命题 1. 假设 $G_1, G_2, \dots, G_n$ 是从无权或加权网络的概率分布中独立生成的 n 个样本。固定 $G \in \mathcal{G}_{[N]}$ ，则当 $n \rightarrow \infty$ 时 $gMD_n^K(G) \xrightarrow{\text{a.s.}} gMD_{pr}^K(G)$ ，并且类似地， $eMD_n^K(G; W) \xrightarrow{\text{a.s.}} eMD_{pr}^K(G; W)$ 。

定理 2（无权网络和加权网络的 eMD）。 假设 $G_1, G_2, \dots, G_n$ 是从无权或加权网络的概率分布中独立生成的 n 个样本。则：

(a) $\sup_{G \in \mathcal{G}_{[N]}} |eMD_n^K(G; W) - eMD_{pr}^K(G; W)| \xrightarrow{\text{a.s.}} 0$ ，当 $n \rightarrow \infty$ 。

(b) 如果 $w_{ij} > 0$ 且 $eMD_{pr}^K(\cdot; W)$ 在 G^c 处唯一地达到最大值，令

$$\tilde{\mathbf{G}}_n = \operatorname{argmax}_{G \in \mathcal{G}_{[N]}} eMD_n^K(G; W),$$

则当 $n \rightarrow \infty$ 时 $\tilde{\mathbf{G}}_n \xrightarrow{\text{a.s.}} G^c$ 。

(c) 如果 $w_{ij} > 0$ 且 $eMD_{pr}^K(\cdot; W)$ 在 G^c 处唯一地达到最大值，令

$$\hat{\mathbf{G}}_n = \operatorname{argmax}_{G \in \{G_1, G_2, \dots, G_n\}} eMD_n^K(G; W),$$

则当 $n \rightarrow \infty$ 时 $\hat{\mathbf{G}}_n \xrightarrow{\text{a.s.}} G^c$ 。

定理2建立了 eMD 的一致收敛性和 (10) 中定义的估计中心的一致性。独立的网络样本可以从许多无权网络模型生成，如 Erdős-Rényi 模型（Gilbert 1959）、随机块模型（Wang and Wong 1987; Zhang, Sun, and Li 2020）

和一系列含噪网络 (Chang, Kolaczyk, and Yao 2020); 同时, 脑神经科学中每个受试者的加权连接网络是独立样本 (Brands 2013; Zhang, Sun, and Li 2023)。gMD 的平行结果在定理 S3 中给出。

我们要求结构权重 w_{ij} 严格为正, 以确保中心网络的可识别性。唯最大化的条件在确定分布或集合的代表性元素时是标准的 (Ziezold 1977; Zuo and Serfling 2000b; López-Pintado and Romo 2006), 这由加权网络 (定理1(a)) 和无权网络 (定理 S1(a)) 的中心处极大性保证。另一方面, 当 $eMD_{pr}^K(\cdot; W)$ 在多个网络中达到最大值 (称为中心网络集) 时, 估计的中心将几乎必然地落入该集合中。在实践中, 我们建议识别几个 (而非单个) 最深网络, 以全面分析网络集合的性质。网络结构可根据实际需要提供灵活的权重。如果感兴趣结构的权重相对于边权是连续的, 则根据连续映射定理, 深度性质和一致性仍然成立。

最后, 我们的理论结果可以自然地推广到边一致存在的稀疏加权网络。我们首先定义一个子图指示符作为一个无权网络, 其中如果一条边一致地出现在这些稀疏加权网络中, 则两个顶点之间存在一条边。然后, 通过将加权网络限制在该子图指示符上, 加权网络的深度性质和收敛理论可以适用于稀疏加权网络。

6 模拟研究

在本节中, 我们进行模拟来评估 eMD_n^2 (记为 eMD) 和 eMD_n^3 (记为 eMD³) 在无权重网络和加权网络中的有限样本性能。对于无权网络, 我们关注有向情形; 而对于加权网络, 我们考虑无向情形。我们将其与 Fréchet 均值 (一种流行的数据排序和中心估计工具) 进行比较。然而, 无权网络的样本空间是离散的, 因此寻找传统的 Fréchet 均值在计算上可能是 NP-难的。这支持了由 Ginestet (2012) 定义的如下受限 Fréchet 均值的选取, 因为它极大地降低了计算复杂度。受限 Fréchet 均值确保估计的中心是一个存在的网络, 这与 eMD 类似。

定义 4 (受限 Fréchet 均值)。 设 $\mathcal{G}_n \subset \mathcal{G}_{[N]}$ 为一个网络集合, $d(\cdot, \cdot) : \mathcal{G}_{[N]} \times \mathcal{G}_{[N]} \rightarrow \mathbb{R}$ 是 $\mathcal{G}_{[N]}$ 上的一个度量。集合

$$G^m = \operatorname{argmin}_{G \in \mathcal{G}_n} \sum_{i=1}^n [d^2(G_i, G)],$$

称为 $\mathcal{G}_n$ 的受限 Fréchet 均值集。

我们同时考虑汉明距离 (Ham) 和弗罗贝尼乌斯距离 (Frob) 来计算受限 Fréchet 均值, 两者均在补充材料的第 SI 节中定义。对于无权网络, 这两种距离是等价的, 因此仅使用 Ham。简而言之, 我们对 eMD 定义如 (10) 的估计中心, 对 Fréchet 均值定义如 (11) 的估计中心。

表2. 三个含污染设定。 n_1 和 n_2 是来自其他模型的异常值样本量, 满足 $n_1 + n_2 = \lceil rn \rceil$ 。|| 模型 | 参数 | 样本量 | ||—||—||—|| 场景 I | SBM | $p_{\text{in}} = 0.16, p_{\text{btw}} = 0.075, p_{\text{in}}^{(\text{per})} = 0.05, p_{\text{btw}}^{(\text{per})} = 0.02$ | $n - n_1 - n_2$ | || SBM | $p_{\text{in}} = 0.5, p_{\text{btw}} = 0.2, p_{\text{in}}^{(\text{per})} = 0.05, p_{\text{btw}}^{(\text{per})} = 0.02$ | n_1 | || ER | $p = 0.5, p^{(\text{per})} = 0.1$ | n_2 | || 场景 II | SBM | $p_{\text{in}} = 0.16, p_{\text{btw}} = 0.075, p_{\text{in}}^{(\text{per})} = 0.05, p_{\text{btw}}^{(\text{per})} = 0.02$ | $n - \lceil rn \rceil$ | || SW | $d = 3, p_{\text{re}} = 0.5, p_{\text{re}}^{(\text{per})} = 0.01$ | $\lceil rn \rceil$ | || 场景 III | SBM | $p_{\text{in}} = 0.16, p_{\text{btw}} = 0.075, p_{\text{in}}^{(\text{per})} = 0.05, p_{\text{btw}}^{(\text{per})} = 0.02$ | $n - n_1 - n_2$ | || RGG | $r = 0.175, \sigma^{(\text{per})} = 0.2$ | n_1 | || ER | $p = 1$ | n_2 |

6.1 无权网络

在第一个模拟中, 我们比较 eMD 和 Ham 在四种常见模型下中心估计的稳健性: Erdős-Rényi 模型 (ER) (Erdős and Rényi 1960)、随机几何图模型 (RGG) (Penrose 2003)、随机块模型 (SBM) (Holland, Laskey, and

Leinhardt 1983) 和小世界模型 (SW) (Watts and Strogatz 1998)。对于 ER 模型, 边出现的概率设为 p 。RGG 是定义在单位正方形上的邻近图, 球的半径设为 r 。对于 SBM, 设置块数为3, 块大小随机, 块内和块间边的概率分别记为 p_{in} 和 p_{btw} 。对于 SW 模型, 格点的度设为 d , 重连概率设为 p_{re} 。为保证单峰性, 首先通过其中一个模型生成中心网络 G^c , 然后通过扰动 G^c 获得网络集合。我们对不同模型采用特定的扰动策略。

我们考虑 $N = 30$ 和200个顶点的网络, 样本量 $n = 50, 100, 200, \dots, 500$ 。 $N = 200$ 的结果与 $N = 30$ 类似, 因此延迟到补充材料的第 SIII.1 节。我们考察了三个污染场景, 大部分数据来自 SBM 模型, 异常值来自其他模型。对于每次运行, 我们使用 eMD 和 Ham 估计中心网络。估计精度 (EA) 通过真实中心 (G^c) 与估计中心 ($\hat{G}^c$) 之间的加权汉明距离来评估:

$$EA(G^c, \hat{G}^c) = \sum_{i \neq j}^N w_{ij} |A_{ij}^c - \hat{A}_{ij}^c|,$$

其中 $W = (w_{ij})$ 是结构权重矩阵。具有较小 EA 的估计中心更接近真实中心。我们重复每个场景200次。EA 的平均值和置信区间如图2所示。 $K = 2$ (eMD) 或 $K = 3$ (eMD³) 的选择在性能上产生可忽略的差异。因此, 在后续讨论中我们专注于 $K = 2$ 。eMD 和 Ham 都随着样本量的增加而变得更精确。eMD 在中心网络估计方面显然表现更好, 具有更低的 EA。eMD 在面对不同污染程度的各种异常值污染数据时也是稳定的。相比之下, Ham 对异常值敏感, 随着污染比例的增加, 估计偏差变得显著。

我们使用第二个模拟来检验结构权重的有效性。考虑两个模型: 优先连接 (PA) 模型 (Barabási and Albert 1999) 和博客网络数据 (Gopal 2007)。对于 PA 模型, 通过顺序添加 N 个顶点并扰动边来生成样本。对于博客网络数据, 使用146个顶点和187条边的有向网络作为中心网络。对于两个模型, 我们使用三个结构权重: 等权重、顶点权重和边权重。eMD 在两种模型下都优于 Ham。此外, 具有适当结构权重的 eMD 可能进一步优于具有等权重的 eMD。

6.2 加权网络

我们使用加权随机块模型 (WSBM) (Aicher, Jacobs, and Clauset 2014, 2015) 和具有高斯扰动的随机几何图模型 (RGG) 生成加权网络数据。对于 WSBM, 块内的边权重由指数分布生成, 块间的边权重也由指数分布生成。异常值通过将分布切换为正态分布引入。

我们比较 eMD ($K = 2$)、eMD³ ($K = 3$) 和基于弗罗贝尼乌斯距离的受限 Fréchet 均值 (Frob) 的中心估计性能。在所有场景下, eMD 及 eMD³ 均显著优于 Frob。与无权网络类似, 适当的结构权重可以进一步提升深度方法的性能。随着污染程度增加, Frob 的 EA 迅速恶化, 而 eMD 的 EA 保持相对稳定, 展现出良好的稳健性。

6.3 计算成本

在无权网络设置下比较 eMD ($K = 2$) 和 Ham 的计算时间。eMD ($K = 2$) 的计算成本与 Ham 相当, 且远低于 eMD³。随着 n 增加, eMD 的计算时间几乎呈线性增长, 而 eMD³ 增长更快。这进一步支持了在实践中选择较小 K 的合理性。

7 真实数据分析：脑电图数据

我们将所提出的多重深度应用于一个来自认知心理学实验的脑电图（EEG）数据集（Zhang et al. 1995; Li, Kim, and Altman 2010）。大多数现有的脑连接分析方法依赖于大脑区域之间的功能连接（Khosla, Khandnor, and Chand 2020）。特别地，脑网络分析在研究大脑功能和心理疾病方面发挥着关键作用（Zhou and Li 2014; Rubinov and Sporns 2010; Power et al. 2011）。

在我们的数据集中，61个电极按照国际10-20系统放置在每个受试者的头皮上。该实验由单因素二元设计组成，包含两个水平：受试者观察到目标出现，或受试者观察到目标未出现。每种条件下有30个受试者，并且每个受试者记录一个来自61个电极的脑电图采样段。每个 EEG 段在30到50 Hz的频率范围内处理成一个加权网络，网络规模 $N = 61$ 。我们共有 $n = 60$ 个网络样本，分为目标出现和目标未出现两组，每组30个网络。

我们应用所提出的深度对这些网络进行中心估计和异常值检测。为了评估结构权重的影响，我们尝试了等权重和顶点权重（使用度中心性）。深度值最高的网络被视为中心网络。在我们的分析中，我们识别出深度值排名前五的网络作为中心网络。

为了评估深度在异常值检测中的性能，我们采用基于深度的异常值检测方法。将一个网络的深度值低于经验深度分布的第10百分位数时标记为异常值。我们进行双样本检验来验证两组网络之间的差异，采用基于深度秩和的检验方法（Liu and Singh 1993）。检验结果表明两组之间存在显著差异（ $p < 0.05$ ），与已有的认知发现一致。

8 讨论

本研究为基于公共顶点集构建的网络集合提供了一种稳健的描述方法。通过结合全局和局部网络结构，我们定义了网络型数据的深度概念。这些概念广泛适用于各种网络（如无权或加权、有向或无向）。深度值为网络集合提供了从中心到外围的排序，从而产生一系列基于秩的描述统计量，如中位数和异常值。在构建所提出的深度时，引入了结构权重以进一步考虑结构信息。此外，我们考察了它们在数据深度方面的理论性质，并建立了深度及其诱导的中位数的一致性。我们开发了快速算法以方便实际实施。通过广泛的模拟研究和真实数据示例，评估了新深度的稳健性。

所提出的深度可以被视为网络数据集合的非参数建模。我们已经展示了它们在几个经典任务中的应用，如稳健中心估计、异常值检测和双样本检验。新深度也适用于网络数据分类和聚类（Relión et al. 2019）、动态网络的变点检测（Huang et al. 2020）、稳健社区检测（Martinet et al. 2020）和链接预测（Martínez, Berzal, and Cubero 2017）。

本文的工作提出了几个未来的研究方向。首先，所提出的深度概念在标记网络上效果良好，研究其向未标记网络的扩展是一个自然的下一步。第二，可以将我们的模型框架扩展到包含来自不同顶点集的网络，其中观测值之间顶点数量的变化在动态网络中经常发生。此外，探索边非一致存在的稀疏加权网络的深度性质是一个有趣的课题。另一个方向是将外部信息（如顶点级或样本级协变量）与网络本身结合。需要进一步努力来推导一般子图多重深度的理论性质并开发高效的计算算法。

9 补充材料

+ 压缩文件包含用于重现数值结果的 R 代码。+ 说明性文件包含所提出算法的描述、额外的数值结果和所有理论结果的证明。

10 致谢

我们非常感谢两位匿名审稿人、一位副主编和主编的宝贵意见，这些意见极大地改进了本文。

11 利益冲突声明

我们声明没有竞争性利益。

12 基金资助

本研究由国家社会科学基金一般项目（批准号：24BTJ066）资助。

13 参考文献

（参考文献与英文原版 EMD.md 一致，此处省略翻译以保持引用的准确性。请参阅英文原文获取完整参考文献列表。）

—

注：本文为英文原版”Multiplex Depth for Network-Valued Data and Applications”（Zhang, Deng & Dai, 2025, Journal of Computational and Graphical Statistics）的中文翻译。图表和补充材料请参阅原版文章。